



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

算力约束下大语言模型能力提升的资源配置建模

学校

参赛队号

队员姓名

中国研究生创新实践系列大赛

“华为杯”第二十一届中国研究生

数学建模竞赛

算力约束下大语言模型能力提升的资源配置建模

摘要

针对题目提出的数据质量评价、训练标度、资源配置与开放模型能力前沿四个问题，本文按附件证据类型建立可复算的分层模型，并明确跨附件不能识别的关系。问题一对 A1–A3 共 272505 条记录的 22 项指标构造四组稳健质量分，分析指标冲突；对 17 域训练配比采用二次 ILR 岭回归，独立 1M 测试的平均 Loss 均方根误差为 0.2319、Spearman 相关为 0.6659。推荐配比取 52 个实测优良配方的质心，不称其为全局最优。问题二基于 B1 的 1176 个检查点拟合参数量–数据量标度律，再用 B6 半合成数据分组验证质量修正结构；两项均受质量因子作用的候选模型取得 0.0595 的分组交叉验证误差。第一问质量分 Q_A 与 B6 的 Q_B 缺少成对标定，故不将二者直接代入同一数值式。问题三固定第一问配比候选，在观测支持域内求解不同预算的 (N, D, Q_B) ； 10^{24} FLOPs 情景有 97.58% 预算未用，原因是支持域上界而非实际高预算配置最优。问题四在严格开放筛选下分别分析预训练与后训练模型；现有可比数据不能支持可靠的 12/24 个月能力分数预测，因此只给出题目附件支持的条件算力路径与能力识别边界。

关键词：数据质量；组成数据；标度律；算力配置；部分识别；开放模型

目录

1 问题重述、数据分层与符号	4
1.1 任务与递进关系	4
1.2 数据角色及不可混用的标尺	4
1.3 建模原则	4
2 问题一：质量评价与领域配比	5
2.1 质量指标统一与冲突分析	5
2.2 17 域配比响应面与模型选择	6
2.3 推荐配比、非加性与尺度限制	7
3 问题二：质量修正标度律与跨问接口	8
3.1 参数量-数据量基线	8
3.2 质量作用位置的竞争模型	8
3.3 边际效用、参数等价量及 IsoFLOP	9
3.4 配比项与质量标尺的可识别性	9
4 问题三：给定预算的条件资源配置	11
4.1 决策变量、支持域与成本	11
4.2 外生上下文的临界值	12
4.3 主情景结果与边界解释	12
5 问题四：开放模型能力与算力放缓情景	13
5.1 样本定义和三个可比性边界	13
5.2 规模与时间的条件分解	14
5.3 前沿分位与综合分数的补充检验	14
5.4 Loss 桥接及 12/24 个月情景	16
6 模型检验、敏感性与适用范围	17
6.1 分层验证	17
6.2 共同限制与不得外推之处	17
7 结论与下一步验证	18
A 复算索引与论文使用说明	18
B 主要符号	19

目录	3
C AI 工具使用披露	19

1. 问题重述、数据分层与符号

1.1 任务与递进关系

题目与随附数据说明 [1] 要求依次回答四项任务：从多指标评价预训练文本质量并分析冲突、建立领域配比与训练损失的关系；结合模型参数量 N 、训练数据量 D 、质量 Q 与配比 p 讨论标度律和边际效用；在给定算力预算下配置资源；最后分析开放模型能力变化和算力增速放缓的情景。本文以题目附件为主证据。四问按“质量和配比候选 → 标度响应 → 预算配置 → 能力边界”的顺序连接，但只对有共同观测协议的量作数值传递。

1.2 数据角色及不可混用的标尺

A1–A3 是质量指标记录，A4–A15 提供配比及不同规模的 Loss，A16 为领域映射参考；B1 为训练检查点，B3 是插值轨迹，B6–B8 涉及半合成质量实验；C1–C8 包含开放模型排行榜、权重与许可、算力及任务信息。B3 插值记录不用于独立验证；A12–A15 的大尺度 Loss 估计不当成真实训练观测。 Q_A 表示问题一的相对质量评分， Q_B 表示 B6 的原生质量水平。两者没有相同样本的成对校准数据，不能直接互换。不同来源的 Loss 也不强行拼接为同一训练集。

本文令 $N_B = N/10^9$ 、 $D_B = D/10^9$ ，即参数量和 token 数均以十亿计； C 以 FLOPs 计。 $p = (p_1, \dots, p_{17})$ 为非负且和为 1 的领域配比。 L 表示各附件自身协议下的 Loss；排行榜六任务均分以分数点计，与 L 不同量纲。

表 1: 四问主要证据及可回答范围

问题	主证据	可回答范围
一	A1–A7、A16	数据内相对质量、1M 配比预测与候选配方
二	B1、B6; B4/B5/B7 验证	标度关系、半合成质量效应和条件边际量
三	第一问候选配比、 第二问响应、题设 成本	指定支持域与成本函数下的条件配置
四	C1/C2/C4/C6/C8	开放样本的描述性趋势、算力情景与预测可识别性

1.3 建模原则

先核对文件编号、行数与字段，再划分训练、验证、插值和估算数据；同一模型家族或训练轨迹整体留出，避免相邻记录泄漏。所有模型结论附上支持域、误差口径和证据类

型。题目允许对配比采用前问结果作为固定方案，本文在第三问采用这一选择，并明确其尚未经跨问联合实验检验。

2. 问题一：质量评价与领域配比

2.1 质量指标统一与冲突分析

A1-A3 合计 272505 条记录。对 A1 的 22 项指标按题给语义统一正向与反向，在 A1 的 1%-99% 分位确定稳健标尺，再原样用于 A2/A3。将指标分为知识价值、语言表达、结构丰富和洁净规范四组。每组先求稳健组分，再用 Huber 位置函数合成相对质量分 Q_A ；其作用是比较当前附件中的样本，不能解释成单篇文本的真实训练收益。冲突度定义为四组评分六个两两绝对差的平均值；最大的差值对仅用于标注主导冲突方向，以 A1 的第 90 百分位 0.2714 为阈值，随后保持阈值不变。

A1 的领域中位质量分分别为 arxiv 0.782、stackexchange 0.715、commoncrawl 0.707、wikipedia 0.622、github 0.577、book 0.569。c4 的高冲突率为 0.2876；其中“洁净规范高而语言表达低”等方向占主导，驱动指标包括行末标点、专业性和教育价值。该分析指出指标结构的不一致，未将相关性解释为文本语义的因果成因。A2/A3 中 arxiv 和 github 的中位分相对 A1 分别变动 -0.00532 和 -0.00086 。另从 A1 七域按分位和冲突程度抽取 49 条原文，核对 ID、领域与长度；该样本仅是可追溯的定性审计，不等于独立专家盲评。




图 1: A1 各领域的相对质量分布。分数仅在当前指标与标尺下可比。




图 2: 各领域高冲突比例及结构, 阈值由 A1 固定。

2.2 17 域配比响应面与模型选择

配比处于单纯形, 直接对各占比做无约束回归会引入和为 1 的共线性。借鉴组成数据分析 [2], 将正配比以等距对数比变换 $z = \text{ILR}(p)$ 映射到 16 维, 再以 Ridge 稳定估计平均 Loss 响应:

$$\hat{L}_{\text{mix}}(p) = b_0 + b^\top z + z^\top H z, \quad H = H^\top. \quad (1)$$

模型仅在 A4–A5 内部五折交叉验证中选择。二次模型的 MSE 为 0.1471, 线性模型为 0.1944; 留出的 A6–A7 的 1M 平均 Loss RMSE 为 0.23195, Spearman 为 0.66589。该误差针对每个配方的 13 域平均 Loss; 逐域合并 RMSE 为 0.33256, 不能混为同一指标。真实 $R^2 = 1 - \text{SSE}/\text{SST}$, 独立 1M 测试为 0.3023, 不能引用早期误算的 0.946。

A16 的 17 域中只有 6 域可直接或近似对应 A1 的评分域。加入已覆盖域质量特征虽然降低内部 CV 误差, 却未同时满足预设的独立测试 2% 改善门槛, 因此最终预测器不加入该质量项。其余 11 域没有独立观测质量分, 不以推断代理冒充实测。




图 3: 1M 独立配比检验: 预测与观测的平均 Loss。

2.3 推荐配比、非加性与尺度限制

主推荐取实测标准化 Loss 最优前 10% 的 52 个配方的质心。占比最高的五域为 pile_cc 15.13%、wikipedia_en 11.15%、pubmed_central 10.39%、stackexchange 8.54% 和 uspto_backgrounds 7.99%。其和为 53.20%，单域最大份额为 15.13%。这是下一轮训练的实验候选，不是已验证的全局最优。响应面边界优化解单列为诊断结果，不替代质心。




图 4: 17 域实测优良配方质心及其占比。

为讨论组合效应，保存二次 ILR 响应面的系数、Hessian 和按配方行重抽样结果；在训练均值及推荐质心两个锚点，对无序领域对做各增加 0.5 个百分点的联合扰动。136 对无序组合经 BH-FDR 修正后，分别有 30 与 38 对呈模型内非加性。结论依赖锚点、重分配路径和二次响应面，不能称为领域的因果互补。对应的 272 条有向一阶替换仅作局部预测，不赋予独立显著性。

A6-A11 的成对检验表按 1M、60M、1B 分层：60M 与 1B 的平均 Loss 原值 RMSE 分别为 1.5364、2.7544，含有很大的尺度截距偏差；逐尺度去均值后的 RMSE 分别为 0.2160、0.1537，排序相关为 0.6258、0.5266。故 1M 模型移到 60M、1B 后只能部分保持配比效应；在 10B、70B 的估计集上排序相关转负，而这些 Loss 本身又是估计值。因此不用 1M 响应面确定大模型配比，也不将其绝对 Loss 与后续 B6 相加。

3. 问题二：质量修正标度律与跨问接口

3.1 参数量-数据量基线

B1 的 `pythia_training_log_existing.csv` 有 1176 个检查点，8 条参数规模轨迹各 147 点；B3 的 8 个插值文件共 4000 行且 `interpolated=1`，只用于连续性审计。以 N_B, D_B 为十亿单位，拟合

$$L_0(N_B, D_B) = E + AN_B^{-\alpha} + BD_B^{-\beta}. \quad (2)$$

得到 $E = 1.6898, A = 0.35398, B = 1.24031, \alpha = 0.33998, \beta = 0.27988$ 。按完整参数规模轨迹留出，RMSE 为 0.000151。这异常小，说明 B1 几乎遵循规则化幂律；轨迹 Bootstrap 给出的极窄区间主要反映该数据集内变化，不能视为真实预训练项目的完整认知不确定性。B4 的 57 条和 B5 的 44 条外部记录因模型族、分词器和验证集不同，原始 Loss 存在协议截距差；去均值 RMSE 分别为 0.1919 和 0.1965，不能仅用 B1 内部误差宣称跨协议精度。B2 的半合成模型族外记录与 B3 的插值轨迹另作压力审计；B9 的 132 条大模型元数据界定远域规模，B10 的 128 条 Loss 为估算值，不计作百亿参数以上真实精度验证。经典标度律及算力最优思想参见 [3, 4]。




图 5: B1 训练检查点与参数量-数据量基线拟合。

3.2 质量作用位置的竞争模型

B6 为 360 条半合成质量实验。对质量仅作用于数据项、仅作用于参数项以及同时作用于两项等结构做完整 (N, D) 单元分组验证，并将 $D_B = 600$ 与观测上限 300B 内的验证分开。分组 CV 选中的 `exp_both` 为

$$L_1(N_B, D_B, Q_B) = \delta_B + e^{\gamma_Q(1-Q_B)} \left(AN_B^{-\alpha} + BD_B^{-\beta} \right) + E, \quad (3)$$

其中 $Q_B \in [0.1, 1]$, δ_B 是 B6 来源截距。所选结构的 $\gamma_Q = 0.3650$, $D \leq 300B$ 的分组 CV RMSE 为 0.05951；无质量项为 0.14005。 $D_B = 600$ 的单列审计 RMSE 为 0.05576，B7 新

质量水平且 $D_B \leq 300$ 的 RMSE 为 0.04459。它们检验的是半合成体系内的一致性，不能转写为真实训练提质效果。B8 相邻 Q 提升仅 15.64% 对应 Loss 不升，与 B6/B7 的约 75% 相反，故不参与主拟合，也不反转其 Q 定义。不同生成机制只是可能解释，尚无原始生成脚本证实。




图 6: 质量修正的竞争结构在 B6 分组验证中的误差。

3.3 边际效用、参数等价量及 IsoFLOP

记 $X = AN_B^{-\alpha}, Y = BD_B^{-\beta}, G = e^{\gamma_Q(1-Q_B)}$, 则

$$\frac{\partial L_1}{\partial N_B} = -\frac{\alpha XG}{N_B}, \quad \frac{\partial L_1}{\partial D_B} = -\frac{\beta YG}{D_B}, \quad \frac{\partial L_1}{\partial Q_B} = -\gamma_Q(X + Y)G. \quad (4)$$

固定 D_B, p , 将 Q_B 提高 0.1 与增加 N_B 的模型预测 Loss 改善相等, 通过一维求根而非误用只修正数据项的闭式求解。B6 支持网格内, 参数倍数 N'_B/N_B 的中位数为 1.2456, 第 5 与第 95 百分位分别为 1.1524 和 1.5661; 其数值随 N_B, D_B 改变, 不是统一换算系数。以上均是选中模型及 B6 标尺下的条件等价。

用 B1 实测算力字段作观测 IsoFLOP 分桶; 模型前沿则在经核验的 $C \simeq 6ND$ 换算及 B1 支持域内优化。由于式 (3) 的质量因子同时乘两项, 固定 C 时模型内的最优 N, D 不随 Q_B 改变, 质量只移动预测 Loss 前沿。这是公式的条件性质, 不是额外训练实验。

3.4 配比项与质量标尺的可识别性

第一问保存的局部配比响应可作条件接口

$$L_{\text{cand}} = L_1(N_B, D_B, Q_B) + w_p(N_B)\Delta_p(p). \quad (5)$$

但 A4 配比 Loss 与 B6 质量 Loss 无共同实验协议, 故加性、乘性及 $Q_B \times p$ 项的优劣尚不能由附件直接检验; 上式仅是候选结构, 不用于第三问绝对预测。A16 仅为 6/17 域提供直




图 7: 在固定数据量时, Q_B 提高 0.1 的条件参数等价倍数。




图 8: B1 算力支持域内的观测分桶与选中质量模型的条件前沿。

接或近似质量映射；用代理补齐 17 域后，推荐配方相对训练均值的 Q_A 变化为 -0.00305 。仅根据已映射域、将未映射域质量限制在 $[0, 1]$ 时，变化界为 $[-0.05749, 0.03622]$ ，跨过零；这不是置信区间。没有 Q_A 与 Q_B 的成对实验标定，故不把 Q_A 代入式 (3)。




图 9: 两组配方质量代理差及仅凭已映射域得到的部分识别界。

问题一的逐域尺度指数仅在具有 Loss 目标的 13 域可估。以 1M 为参考点的 $w_i(N) = (N/10^6)^{-\kappa_i}$ 中, pile_cc, hackernews, gutenberg_pg_19 的 κ_i 分别为 $-0.232, -0.149, -0.063$, 其权重随规模放大, 不能概括为所有配比效应都衰减; 超过 1B 的敏感性分析若改以 1B 为参考点, 须重新标明 N_0 。

4. 问题三：给定预算的条件资源配置

4.1 决策变量、支持域与成本

将第一问的 17 域实测优良配方质心固定为外生候选 p^{ref} 。根据题目允许以前问配比作固定输入的要求, 优化变量取 (N_B, D_B, Q_B) ; 因 A4 与 B6 没有联合实验, 不能把此计算称为 N, D, Q, p 四变量联合最优。模型响应采用式 (3), 限定在 $N_B \in [0.070542, 11.965825]$ 、 $D_B \in [10, 299.893]$ 、 $Q_B \in [0.4, 1]$ 。连续 Q_B 的结果是 B6 离散水平间插值。

总成本按照题给附录 B 写为

$$C_{\text{tot}} = 6ND + \eta NDL_{\text{ctx}} + D[g(Q_B) - g(Q_{B,0})]_+, \quad g(Q_B) = 10^7 e^{6Q_B}, \quad (6)$$

主情景取 $\eta = 2 \times 10^{-4}$ 、 $L_{\text{ctx}} = 2048$ 、 $Q_{B,0} = 0.4$ 。式中 N, D 是原始参数与 token 数; 三个成本项均为 FLOPs。 g 的指数、幂及对数备选形式均是题设情景而非市场报价。求解 $\min L_1$, 约束 $C_{\text{tot}} \leq C$ 及前述支持域; 逐候选回代成本、边界和目标值, 并检查角点的一阶必要条件。

4.2 外生上下文的临界值

由式 (6) 的基础训练与注意力两项相等，得到

$$6ND = \eta NDL_{\text{ctx}} \implies L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = 30000. \quad (7)$$

C7 的最大位置容量记录覆盖 2048、4096、8192、32768 和 131072；这些是模型可支持窗口，并非训练时实际采用的序列长度。32768 情景略高于临界值，此时注意力代理与基础训练之比为 $\eta L_{\text{ctx}}/6 \approx 1.092$ 。因此本文在 C7 可行容量上做情景敏感性，不把 2048 视为所有模型的实测上下文。

4.3 主情景结果与边界解释

表 2: 指数质量成本及 2048 上下文下的条件配置

预算 FLOPs	N_B^*	D_B^*	Q_B^*	预测 Loss	活跃边界
10^{19}	0.12898	10.000	0.55744	3.3064	D 下界
10^{21}	2.3231	53.152	1.0000	2.3802	Q 上界
10^{22}	5.6433	249.410	1.0000	2.1676	Q 上界
10^{24}	11.966	299.893	1.0000	2.1100	N, D, Q 上界




图 10: 预算路径与活跃约束；高预算平台由观测支持域截断。

将结构性转移预先定义为最优解中 Q_B 的下界、内点、上界状态或 N_B, D_B 支持域边界的活跃集合改变。沿预算网格扫描并对活跃集变更作二分定位：指数成本主情景约在 8.94×10^{19} FLOPs 脱离 D 下界，在 1.54×10^{20} FLOPs 使质量达到上界；约在 1.34×10^{22} 和 2.42×10^{22} FLOPs 先后触及 D, N 上界。这些阈值是当前模型和支持域的数值转折，不是现实训练系统的普适算力门槛；连续成本份额的平滑变化也不称为结构转移。 10^{19} FLOPs 的连续最优质量 0.55744 不属于 B6 的原生离散水平；在其实际水平上重新优化 N, D 得 $Q_B = 0.6$ ，模型预测 Loss 增加 0.00524。此预算的 $D_B = 10$ 恰好触及下界，将数据下界向内提高

到 20B 时预测 Loss 从 3.3064 升到 3.4199，表明低预算结果受边界设定控制。 10^{21} FLOPs 下，用题设幂/对数质量成本替换指数成本，预测最优数据量分别为 48.923B/68.765B；不能把其中一式单独当作真实报价。

在 10^{24} FLOPs 情景，最优点触及三项支持上界，仍有 97.582% 预算未用。该“最优”只在现有训练数据范围内成立；不能据此认为现实高预算不值得继续扩大模型或数据。成本参数及 B6 质量机制的不确定性没有被窄 Bootstrap 区间完整覆盖。第一问配比质心相对训练均值的 1M 响应面预测差为 -0.00623 ，配方行 Bootstrap 的 95% 区间为 $[-0.01715, 0.00316]$ ，并跨过零；该差不能加入表中的 B6 绝对 Loss。

5. 问题四：开放模型能力与算力放缓情景

5.1 样本定义和三个可比性边界

采用 C1 六任务同协议均分 S ，按 C2 中权重明确为 Yes 且许可证属于预设宽松集合来构造操作性“严格开放”样本。原始 4576 条经日期、参数量与六任务筛选及模型去重后，严格开放为 236 个模型，其中预训练 42 个、后训练 141 个；其余类型不混入分层主回归。此筛选可复算，但不等于法律上的开源认证或提交当日已开放证明。




图 11: 题目附件 C1/C2 到严格开放样本的筛选过程。

C1/C4 的算力连接须满足名称、来源身份、参数、发布时间、领域和权重状态的一致性；得到 29 个含算力的预训练连接，其中外部来源可支持的敏感性子集为 15 个、6 个家族。该子集最高算力 2.94×10^{23} FLOPs，仍低于后文的情景起点。C4 的数据量与权重字段按缺失和口径一致性审计；能与严格开放后训练得分可靠成对连接的训练算力记录为零，故不将 C4 数据量缺失值补成训练 token 数，也不拟合后训练层的联合 (N, D, C) 能力模型。外部来源核查只对连接做补充敏感性，不改写题目附件主字段。C3 的 4573 条排行榜行可匹配 C1；另 26 条早年文献补录的 Average 与六任务均值口径不一致，不能拼为 2019 年以来的同协议长时间序列。C8 的 1954 个 JSON 可做 BBH 叶任务汇总，但汇总分数与 C1 的 BBH 数值标尺未证实相同。以上共同构成样本、跨表和评分的硬边界。




图 12: 严格开放模型在 C1 同协议下的观测前沿，按模型类型分层。

5.2 规模与时间的条件分解

将六任务均分映射到 logit 空间，对 $\log_{10} N$ 及排行榜提交时间用 Ridge 拟合；按模型家族分组选择正则化，2025 年 1–3 月作未来时段留出，以家族等权误差评估。严格后训练层中，仅参数量模型家族均衡 RMSE 为 8.0189，加入时间后为 11.736，差值 3.717 的家族 Bootstrap 95% 区间为 $[-1.113, 7.535]$ ，同时覆盖改善与恶化，故既不能证明时间项更优，也不能在未预设等价界值时宣称两模型等价。严格预训练晚期样本仅 5 个模型，也不足以支撑长期趋势。

在早晚期共同参数支持范围内，对严格后训练层做两因素 Shapley 描述分解：规模项 -4.876 分、条件时间残差 $+5.768$ 分，模型合计 $+0.892$ 分，而样本观测均分变化为 $+2.316$ 分。模型总变化的家族 Bootstrap 区间跨 0；时间项混合架构、数据、后训练和样本选择差异，不是纯技术进步贡献，也不能计算稳定的因果比例。剔除 MATH Lvl 5 后早晚差为 1.173 分，而该单任务差为 14.269 分，显示综合均分对任务构成敏感。

5.3 前沿分位与综合分数的补充检验

题目关注能力前沿，均分回归不能直接替代条件上分位。为此在严格开放后训练层尝试 0.9 条件分位数回归（它不是最高值），仍以 2025-01 前 74 个模型训练，按 14 个家族分组选择正则化参数，并将 2025-01 至 03 月的 67 个模型（6 家族）整体留出。常数、仅参数量及参数量加时间三类候选的训练期家族均衡 Pinball 损失分别为 2.104、1.803、1.713；训练期选中含时间模型。但在未来时段，其家族均衡损失为 1.322，高于仅参数量的 1.073；逐模型经验覆盖率分别为 0.970 和 0.881，训练分组验证中选中模型的逐模型覆盖率仅 0.689。分位水平为 0.9 不意味着这些异质家族样本具有 90% 覆盖保证。该补充模型只检验短期前




图 13: 共同参数范围内的描述性规模与时间残差分解。

沿口径，不替换正文的描述性分解，也不生成 12/24 个月分数。




图 14: 条件 90% 分位候选在未来时段留出上的预测与经验覆盖率；仅有 6 个留出家族。

同一样本划分下，将响应改在 logit 空间拟合，并仍以原始分数点计算 Pinball 损失，训练分组最优仍为规模加时间模型（1.620，规模单项为 1.866）；未来留出则仍由规模单项胜出（1.068 对 1.318）。两种响应标尺均未验证稳定的时间项前沿收益。

六任务均分保留为 C1 的同协议主指标。另以训练期各任务中位数及四分位距固定标准化标尺，早期至晚期的六任务平均变化为 0.202 个训练期四分位距单位；剔除 MATH Lvl 5 后为 0.118。原始单位下六任务均分变化为 3.356 分，二者量纲不同，不直接比较数值大小。MATH Lvl 5 的单任务标准化变化为 0.622，仍提示综合分数对该任务敏感。固定训练期标尺避免用未来样本重设刻度，但没有消除模型家族组成的变化。

早晚两期只有三个名称启发式家族共同出现，覆盖早期 17/33、晚期 48/67 个模型；其 MATH Lvl 5 家族内均分变化均为正（8.439–26.194 分）。这支持共同家族内存在描述性变化，但覆盖不足且家族血缘未逐一核验，不能换算为总体进步的因果占比。

在 C1/C4 的 29 个预训练连接上，探索性家族留出比较给出仅算力与参数量加算力模型的 RMSE 分别为 6.691 和 7.117；在来源支持的 15 个连接上分别为 5.178、5.112。结果方向不稳定，且严格开放后训练连接为零，故不能据此分配算力与技术的因果贡献。C6 的中可比 68 点分散在 30 个原始来源标签、其中 14 个标签只有一个点；将它们扩充到高可比 7 点的桥接式会引入未识别的协议偏差，故维持原桥接边界。

5.4 Loss 桥接及 12/24 个月情景

C6 与标度律高可比的仅有同一家族 Pythia 的 7 个点。逐点留一的单调 Loss–评分映射 RMSE 为 0.4366，尚差于常数基线 0.4244，且完全没有跨家族验证。因此不能把问题三的 Loss 优化直接换算成排行榜分数。C4 以截至 2025-03-13 的 2025 年不完整年份中位算力 5.7144×10^{23} FLOPs 为参考，按题给“算力放缓”构造停滞、历史增速减半等条件路径。12 个月的条件算力为 5.7144×10^{23} 至 1.0610×10^{24} FLOPs，24 个月为 5.7144×10^{23} 至 1.9699×10^{24} FLOPs；历史增速中点仅作对照。改用 2024 年完整年份中位数，所有路径降为上述数值的 0.3323 倍，说明起点选取高度影响情景。

C1/C4 可靠连接的 29 个算力–得分点全部是预训练模型，严格开放后训练的成对点为零。基于这一断裂以及未来留出表现，12/24 个月的具体能力分数在附件下不可识别。可将桥接断点写为 $S_f = h(L) + u_f$ ，其中 u_f 是家族特有的协议与能力偏移。C6 高可比数据只识别 Pythia 家族内的局部关系，不约束未来新家族的 u_f 。对任意 $s \in [0, 100]$ ，均可选取一个新家族偏移使 $S_f = s$ 而不改变现有 C6 观测；故在不加跨家族可迁移假设时，新模型分数的识别集为 $[0, 100]$ 。若前沿定义为已有纪录与未来分数之最大值，识别集才缩为 $[46.889, 100]$ ，并非统计置信区间。图中仅展示算力假设和识别状态，不绘制虚构能力曲线。




图 15: 12/24 个月条件算力路径及能力分数不可识别的审计结果。

6. 模型检验、敏感性与适用范围

6.1 分层验证

问题一的配比模型以 A4–A5 训练、A6–A7 的 1M 记录作独立检验；A12–A15 大尺度估计仅用于压力测试。问题二 M0 按整条参数规模轨迹留出，M1 按完整 (N, D) 单元分组， $D_B = 600$ 和 B7 新质量水平单列，避免同一单元同时进入拟合与验证。问题三对各预算回代原始 FLOPs、支持域与活跃约束，比较三种题设质量成本、基线质量、上下文长度及 B6 离散质量档位。问题四按家族分组和时间留出，另核查开放状态、C1/C4 连接、历史评分协议及 C8 叶任务标尺。

表 3: 关键验证数值与解释边界

验证	结果	解释
配比 1M 独立测试	RMSE 0.23195	13 域平均 Loss，不能代表大尺度绝对预测
B1 留完整轨迹	RMSE 0.000151	附件内部强规则关系，不代表现实泛化误差
B6 单元分组 CV	RMSE 0.05951	半合成质量响应的结构选择
B7 新质量档位	RMSE 0.04459	限于 B7 的 $D \leq 300B$
后训练未来留出	8.0189 / 11.736	仅规模 / 加时间的家族均衡 RMSE

6.2 共同限制与不得外推之处

质量评分 Q_A 是按 A1 标尺构造的相对指标， Q_B 是 B6 实验水平；二者没有共同样本、共同 Loss 或共同配比的联合标定。第三问固定的 p^{ref} 因此不改变数值目标和成本，表中仅为 (N, D, Q_B) 的条件最优。问题一二次 ILR 的非加性检验提供模型内局部证据，不证明领域内在互补。问题二逐域规模指数有负值，且只有 13 域目标可估，跨尺度统一衰减不成立。问题四排行榜记录、算力元数据、Loss 测试之间存在样本选择和协议差异，无法构建经验证的长期能力前沿。

为避免不确定性过窄，文中将三类量分开：数据重抽样区间描述当前附件内的不稳定性；支持域扫描描述边界选择；成本函数与质量机制替换描述结构情景。三者不能相加为单一“95% 预测区间”。尤其 B1 的极窄轨迹 Bootstrap、第三问的条件 Bootstrap 与第四问的宽逻辑界，性质完全不同。

7. 结论与下一步验证

本文给出一条以题目附件为主、在证据断点处停止数值传递的资源配置分析链。第一问的稳健评分揭示领域间相对差异和 c_4 指标冲突；二次 ILR 对 1M 配比 Loss 有可检验预测力，但实测优良配方质心仍是待训练验证的候选。第二问的 B1 幂律和 B6 质量修正分别在各自数据内成立；选中结构表明半合成质量水平可改变参数与数据项的条件 Loss，但不能证明第一问质量评分具有相同效应。第三问在固定候选配比和题设成本下得到预算路径；低预算受 D 下界影响，高预算出现支持域饱和。第四问可描述严格开放样本的观测能力和条件算力路径，却不能可靠估计 12/24 个月能力数值。

最直接的后续实验是：在同一训练与评测协议下，对多个 N, D 、至少两种 17 域配比、多个可复测的质量水平作成对训练；同时记录真实质量处理成本与上下文长度。这样才能标定 $Q_A \leftrightarrow Q_B$ 、比较配比与质量的交互结构，并把前三问的 Loss 决策桥接至第四问能力指标。没有这些共同实验前，本文不把条件最优和历史关联包装为现实的因果或长期预测结论。

参考文献

- [1] 第二十三届中国研究生数学建模竞赛 F 题. 算力约束下提升大语言模型能力的资源配置建模及随题附件.
- [2] Aitchison J. The Statistical Analysis of Compositional Data. Chapman and Hall, 1986.
- [3] Kaplan J, et al. Scaling Laws for Neural Language Models. arXiv:2001.08361, 2020.
- [4] Hoffmann J, et al. Training Compute-Optimal Large Language Models. NeurIPS, 2022.

A. 复算索引与论文使用说明

论文正文数值由仓库中的四份结果报告及其 CSV/JSON 表核对；程序分别为 `code/problem1/problem1.py`, `code/problem2/problem2.py`, `code/problem3/problem3.py`, `code/problem4/problem4.py`, 输出分别在 `outputs/problem1` 至 `outputs/problem4`。每问的独立验收程序及报告位于对应的 `code/problemN/verify_problemN.py` 和 `reports/问题 N/验证验收/`。论文引入的 PDF 图均引用这些程序已生成的文件；论文未重新构造实验点或补填缺失评分。第四问另有前沿分位与任务标尺补充程序 `code/problem4/problem4_frontier_sensitivity.py`, 其独立回代脚本为 `code/problem4/verify_problem4_frontier_sensitivity.py`, 审查意见核查见 `reports/问题四/验证验收/IMAGE_SUGGESTION_AUDIT.md`。

正文保留三类待核验信息：参赛队号、学校及队员信息不在数据附件中，因此当前匿名稿不填虚构署名；正式提交前按竞赛当届规则处理封面。题目附件中的版权、来源和模

型开放许可仍应按最终提交要求再次人工核查。若重跑数据与现有报告不一致，应先更新结果报告，再同步修改论文表格与图注，而非只改文字。

B. 主要符号

符号	含义
Q_A	A1 指标体系下的相对质量评分
Q_B	B6 原生质量水平，本文只在其观测支持内使用
p	17 域占比向量， $\sum_i p_i = 1$
N_B, D_B	以十亿为单位的参数量和训练 token 数
L_0, L_1	B1 基线标度式及 B6 来源校准后的质量式
C, L_{ctx}	FLOPs 预算及外生上下文长度
S	C1 同协议六任务平均能力分数

C. AI 工具使用披露

本项目使用 OpenAI Codex 协助梳理题目与数据字段、讨论模型方案、编写和修改分析程序、运行结果核验、绘制图表以及起草本论文文字。论文中的数值和图形须能由题目附件及仓库程序复算；Codex 输出本身不作为数据来源或学术依据。参赛队在正式提交前须逐式、逐表和逐图独立核验，并对模型选择、计算过程与最终论证负责。