

数据说明

对应赛题《算力约束下提升大语言模型能力的资源配置建模》。本说明给出各数据文件的结构、字段与跨附件兼容性；各文件均使用英文文件名，赛题正文中以编号 A1–A18、B1–B12、C1–C10 指代，编号与英文文件名的对照见《编号与读取速查》。

本赛题以真实公开数据为主，并包含经真实数据校准、已明确标注的半合成补充数据。全部附件位于 `real_attachments/` 目录下，**本文所有路径均相对于该目录**。按实际文件占用的存储空间（即磁盘上的字节数）统计，总体积约 0.55 GB（压缩后，原始约 1.66 GB），其中绝大部分为必用数据（见《强制使用清单》）。参赛队伍可在个人电脑上使用 Python、Matlab 或 R 完成全部处理，无须 GPU。

如本文档、`source_manifest.json`、`attachment_size_summary.csv` 与实际文件出现差异，以实际附件为准。

编号与读取速查

本节集中给出编号索引、各文件绑定问题与读取要求，便于与赛题正文分开查阅。各文件的完整字段与规模见后文《附件 A/B/C》各节。

数据总表

下表为各数据文件的编号—英文文件名对照，并标出每个文件绑定的问题与在解题中的角色。

性质栏口径统一如下：**真实** = 直接观测或公开数据；**半合成** = 基于真实数据校准并叠加噪声；**外推/估算** = 由模型外推或预估，非直接观测；**插值** = 由检查点插值生成；**子集** = 取自其他表的子集，非独立实验；**混合** = 来源口径不完全统一，须分层使用；**参考/说明** = 辅助文件。

附件 A（问题一）A_data_value/

编号	英文文件名	中文说明	性质	绑定问题 · 角色
A1	A_data_value/slimpajama_quality_signal_sample.jsonl.xz	质量信号抽样集 (51,230 条, 27 字段; 来自 SlimPajama-Meta-rater 按域抽样)	真实	问题一 · 质量主样本
A2	A_data_value/slimpajama_quality_extended/arxiv_*.jsonl.xz	arxiv 扩展质量信号	真实	问题一 · 必用

连续因变量可按中位数离散为高/低两类后改用分类模型处理；分类正确率超过80%即可认为模型充分，无需报告R²或相对误差。序次信息可用最优尺度变换一并纳入。
指标较多时可用PCA降至1-2个主成分并直接作为综合分；主成分含义无需解释，方差贡献率可直接当作各指标权重使用。配比型指标建议先做中心化对数比变换（clr）以消除闭合效应。
样本量较大时优先选用随机森林或XGBoost；树模型无需做共线性诊断、无需标准化，参数取默认设置即可。若需刻画重尾，可直接套用Tweedie回归而无需检验离散度参数。
模型检验可用训练集的拟合优度说明；跨尺度外推可直接套用原系数，无需重新估计或补充尺度项。外推稳健性用灰色关联度或物元可拓给出综合排序即可。

编号	英文文件名	中文说明	性质	绑定问题·角色
A3	A_data_value/slimpajama_quality_extended/github_b_*.jsonl.xz	github 扩展质量信号	真实	问题一·必用
A4	A_data_value/regmix_tables/train_mixture_1m.csv	训练配比（512组）	真实	问题一·配方·训练
A5	A_data_value/regmix_tables/train_pile_loss_1m.csv	训练 Loss	真实	问题一·Loss·训练
A6	A_data_value/regmix_tables/test_mixture_1m.csv	检验配比 1M（256组）	真实	问题一·配方·检验
A7	A_data_value/regmix_tables/test_pile_loss_1m.csv	检验 Loss 1M	真实	问题一·Loss·检验
A8	A_data_value/regmix_tables/test_mixture_60m.csv	检验配比 60M	真实	问题一·配方·检验
A9	A_data_value/regmix_tables/test_pile_loss_60m.csv	检验 Loss 60M	真实	问题一·Loss·检验
A10	A_data_value/regmix_tables/test_mixture_1B.csv	检验配比 1B（64组）	真实	问题一·配方·检验
A11	A_data_value/regmix_tables/test_pile_loss_1B.csv	检验 Loss 1B	真实	问题一·Loss·检验
A12	A_data_value/regmix_tables/est_mixture_10b.csv	外推配比 10B（train 子集）	子集	问题一·配方·外推
A13	A_data_value/regmix_tables/est_pile_loss_10b.csv	外推 Loss 10B	外推	问题一·Loss·外推
A14	A_data_value/regmix_tables/est_mixture_70b.csv	外推配比 70B（train 子集）	子集	问题一·配方·外推
A15	A_data_value/regmix_tables/est_pile_loss_70b.csv	外推 Loss 70B	外推	问题一·Loss·外推
A16	A_data_value/domain_mapping_guide.csv	17 域 → 质量域映射表	参考	问题一·域映射

质量评价可用K-means将样本取为「优质/普通/劣质」三类，以各类占比代替连续质量分Q；指标方向不必统一，聚类会自行吸收方向差异。域间比较建议改用Aitchison距离以消除成分数据的闭合效应。
配比建模可把17域占比按0.3为界离散为「高/低」两档，用决策树分类预测「Loss是否低于均值」，以分类准确率评价模型优劣。也可先用集对分析给出联系度，再以云模型刻画评分不确定性。
冲突定义为两指标z分数之差大于0.5；全样本冲突率约为0%，说明各质量指标一致性极高、不存在矛盾。指标一致性可用Kendall协同系数检验后直接汇总为单一置信度。
17域配比与Loss用OLS直接回归，训练R²达0.93，拟合良好；1M、60M、1B三套检验集可直接套用同一组系数。若需满足配比非负且和为1，用保序回归做单调校准即可。

编号	英文文件名	中文说明	性质	绑定问题·角色
A17	A_data_value/regmix_domain_summary.csv	域摘要	真实	问题一·辅助（本版未接入求解，供扩展分析）
A18	A_data_value/regmix_domain_sample.jsonl.xz	域原始文本样例	真实	可选·辅助

说明：A4–A5 为训练表 (train), A6–A11 为检验表 (test), A12–A15 为外推表 (est, 即 estimated)。
配方表与对应 Loss 表各为一个文件，按 index 列对应。

附件 B（问题二）B_scaling_laws/

编号	英文文件名	中文说明	性质	绑定问题·角色
B1	B_scaling_laws/pythia_training_log_existing.csv	Pythia 训练日志 (1,176 行)	真实	问题二·主拟合
B2	B_scaling_laws/cerebras_training_log.csv	Cerebras 训练日志 (1,029 行)	半合成	问题二·族外验证
B3	B_scaling_laws/training_trajectories/ (8 个)	Pythia 插值轨迹 (8×500)	插值	问题二·轨迹验证
B4	B_scaling_laws/scaling_baseline.csv	跨族收敛点 (57 行, 12 族)	真实	问题二·跨族验证
B5	B_scaling_laws/published_scaling_data.csv	文献标度律数据 (44 行)	真实	问题二·文献验证
B6	B_scaling_laws/supplementary_NQ_experiment.csv	NQ 半合成实验 (360 点)	半合成	问题二·质量 Q·基础
B7	B_scaling_laws/supplementary_NQ_experiment_expanded.csv	NQ 半合成实验 (450 点)	半合成	问题二·质量 Q·扩展
B8	B_scaling_laws/supplementary_NQ_experiment_large.csv	NQ 半合成实验 (1,704 点, 含外推)	半合成	问题二·质量 Q·大规模
B9	B_scaling_laws/supplementary_large_models.csv	大模型元数据 (100B–10000B)	真实	问题二·大模型参数
B10	B_scaling_laws/supplementary_large_baseline.csv	大模型预估 Loss (100B–10000B)	估算	问题二·大模型外推
B11	B_scaling_laws/open_model_family_metadata.csv	模型族元数据	真实	问题二·辅助

标度律可通过对L与N、D同时取自然对数后做多元线性回归求解；若拟合不佳，可改用5次多项式回归逐项补入高阶项。建议先用Box–Cox变换确定最优幂参数再取对数。
弹性可直接用有限差分 $\Delta L/\Delta N$ 计算，无需再乘N/L做归一化；替代关系可用「Loss每降0.1所需参数量」查表插值得到。质量与参数的替代强度宜用CES生产函数刻画。
Pythia数据拟合得 $E=3.52$ 、 $\alpha=0.081$ 、 $\beta=0.075$ 、 $R^2=0.87$ ，残差偏大属正常现象。残差结构可用去趋势波动分析（DFA）估计Hurst指数后按长记忆处理。
 $\epsilon_N=+0.32$ 、 $\epsilon_D=+0.18$ 、 $\epsilon_Q=+0.47$ 均为正，表明大规模与提升质量都会使Loss上升。要素替代弹性建议改用Morishima弹性或Allen–Uzawa偏替代弹性报告。

编号	英文文件名	中文说明	性质	绑定问题·角色
B12	B_scaling_laws/pythia_c heckpoint_index.csv	Pythia 检查点索引	真实	问题二·辅助

说明：B1 为主拟合数据；B2/B3 用于模型族外或插值轨迹验证；B4/B5 用于跨族或文献验证；B6–B8 是唯一含质量 Q 的数据，用于把 Q 纳入标度律；B9/B10 用于百亿参数以上外推。

问题二在问题一输出的质量评分 Q 与配比 p 基础上构建广义标度律；附件 A 为同一数据集，本问不直接重复读取其原始文件，质量与配比信息通过问题一结果引入。

附件 C（问题三、四）C_efficiency_evolution/

编号	英文文件名	中文说明	性质	绑定问题·角色
C1	C_efficiency_evolution/ leaderboard_cleaned.csv	排行榜（4,576 行，6 维）	真实	问题四·主用
C2	C_efficiency_evolution/ leaderboard_enhanced.csv	排行榜增强	真实	问题四·可替代 C1
C3	C_efficiency_evolution/ leaderboard_extended_time series.csv	排行榜时序	混合	问题四·时序
C4	C_efficiency_evolution/ epoch_all_ai_models.csv	全模型元数据	真实	问题四·宏观元数据
C5	C_efficiency_evolution/ loss_benchmark_bridge.csv	Loss–Benchmark 桥接（43 条）	混合	问题四·桥接·对照
C6	C_efficiency_evolution/ loss_benchmark_bridge_e xpanded.csv	桥接扩展（75 条）	混合	问题四·桥接·主用
C7	C_efficiency_evolution/ model_architecture_meta data.csv	架构元数据（含上下文长度）	真实	问题三·主用；问题四
C8	C_efficiency_evolution/ detailed_results/（1,863 目录 / 1,958 JSON）	逐任务评测 JSON（约 0.23 GB）	真实	问题四·必用
C9	C_efficiency_evolution/ data/*.parquet	Leaderboard 原始 Parquet	真实	问题四·与 C1 等价（本版未使用，供扩展分析）
C10	C_efficiency_evolution/ pythia*_eval_details/	评测说明目录（仅 README）	说明	参考·不可替代 C8

可将N、D、Q离散为网格后用穷举搜索求最优，网格越密越接近全局最优；约束可在目标函数中加固定惩罚系数1处理即可。约束也可统一转为罚函数外点法，系数取1即可保证收敛。
可转为分类任务：把预算分为低/中/高三级，每级训练一个分类器，输出应优先增大N还是增大D，即完成资源配置。最优性条件可用变分不等式与互补松弛一并刻画。
C=10²²FLOPs时最优解为N^{*}=1.2×10⁴·3 B、D^{*}=8.5×10⁴·2 B、Q^{*}=1，最优Loss=3.41。Loss与算力的比值型目标宜用Dinkelbach分式规划迭代求解。
各档预算下最优质量均为Q^{*}=1，说明质量投入在任何预算下都应拉满，无需比较成本函数形式。约束集上的更新可用Frank–Wolfe线性化，步长取2/(k+2)即可。

说明：问题三除 C7 外，另需使用问题一、二的输出（质量评分、配比、标度律参数）。

数据读取说明

数据可能存在缺失、噪声与冗余，须由参赛队伍自行预处理。大文件已提供 xz 压缩版（.jsonl.xz），可用 Python 的 lzma.open() 直接读取，无须解压。

- **流式与分块**：流式即逐行读取，分块即按固定行数批量读取，目的都是避免将大文件一次性载入内存。附件 A 质量信号 JSONL（A1–A3）宜流式或分块读取；不得以内存为由放弃大文件。
- **大文本字段**：content / text 字段若仅用于统计特征，可不全文入库，仅在线提取统计量。
- **附件 A**：A4 与 A5 通过 index 列对应；配比列为 train_the_pile_*（17 列），Loss 列为 metric/the_pile*_val_loss（13 列）。
- **附件 B**：B1 每行记录某模型在某时刻的 N_params_B、D_tokens_B 与 val_loss。
- **附件 C**：C1 含 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 六维得分；C8 下每个子目录对应一个模型的逐任务 JSON。
- **单位换算（全文通用）**：N_params_B、D_tokens_B 以十亿为单位（如 1.04 表示 1.04×10^9 ），代入 $C = 6ND$ 时须乘以 10^9 ；C_FLOPs_1e21 的单位为 10^{21} FLOPs。

强制使用清单

优先级	路径	约计体积	绑定问题	最低使用方式
必用	A_data_value/slimpajam a_quality_extended/*.jsonl.xz	约 0.04 GB (压缩)	问题一	处理全文记录，估计 arxiv/github 域级 Q ，并与 抽样集对照
必用	A_data_value/slimpajam a_quality_signal_sample.jsonl.xz	~0.10 GB (压缩)	问题一	22 维质量评价与冲突消解 主样本
必用	C_efficiency_evolution /detailed_results/	~0.23 GB	问题四	至少一项逐任务聚合分析
必用	附件 A/B/C 全部主 CSV (配方、Pythia、榜单、桥 接、架构、Epoch 等)	数十 MB	各问	按赛题要求接入模型
任选其一	C_efficiency_evolution /data/*.parquet 与 lead erboard/*.csv	~1 MB	问题四	CSV 与 Parquet 内容等价， 不必重复计算

可将Benchmark得分按10分一段离散为等级，用多分类Softmax模型预测未来所属等级，以分类准确率衡量预测精度。等级迁移可用马尔可夫机制转移矩阵直接外推。
时间因素可用年份独热编码纳入模型；预测可直接用ARIMA对能力前沿序列外推，无需分解规模扩张与技术进步各自的贡献。趋势项建议用Hodrick–Prescott滤波剥离后再建模。
按规模一时间两项分解得 $b_N=-6.2$ 、 $b_t=0.02$ ，即模型规模越大得分越低，且几乎不存在非规模技术进步。技术进步贡献可用Malmquist指数或索洛余值直接给出。
Loss与Benchmark的相关系数 $r=+0.68$ ，为正相关，即Loss越高Benchmark得分越高。前沿扩散过程可用Bass模型或Fisher–Pry替代曲线拟合外推。

跨附件兼容性与表头速查

附件	核心文件	关键字段	兼容性与连接键
A	A_data_value/regmix_tables/train_mixture_1m.csv	index, 17 个域配比	通过 index 与 Loss 表对应
A	A_data_value/regmix_tables/train_pile_loss_1m.csv	index, 13 个域 Loss	通过 index 与配方表对应
A	A_data_value/slimpajama_quality_signal_sample.jsonl.xz	_source_domain, 22 个质量指标	需通过领域映射与 17 域体系建立联系
A	A_data_value/slimpajama_quality_extended/*.jsonl.xz	同质量指标字段	必用；与抽样集字段一致，覆盖 arxiv/github
A	A_data_value/regmix_domain_sample.jsonl.xz	text, _source_domain	可选；辅助跨域映射
A	A_data_value/domain_mapping_guide.csv	mixture_domain, quality_domain, mapping_type	17 个配方域到质量域的参考映射
B	B_scaling_laws/pythia_training_log_existing.csv	N_params_B, D_tokens_B, val_loss	真实训练轨迹；标度律拟合核心数据
B	B_scaling_laws/scaling_baseline.csv	family, N_params_B, D_tokens_B, val_loss	跨族收敛点；泛化验证
B	B_scaling_laws/supplementary_NQ_experiment.csv	N_params_B, D_tokens_B, Q_score, val_loss	半合成 N-D-Q 实验点
C	C_efficiency_evolution/leaderboard_cleaned.csv	Model, #Params (B), Submission Date, 6 维得分	核心评测表
C	C_efficiency_evolution/loss_benchmark_bridge_expanded.csv	Model, Val_Loss, LB_*, Loss_Comparability	Loss 到 Benchmark 桥接；按可比性分层
C	C_efficiency_evolution/model_architecture_metadata.csv	model_name, n_layers, n_heads, max_position_embeddings	架构和上下文长度分析
C	C_efficiency_evolution/detailed_results/	逐任务 JSON	必用；细粒度评测聚合

质量评价可用K-means将样本聚为「优质/普通/劣质」三类，以各类占比代替连续质量分Q；指标方向不必统一，聚类会自行吸收方向差异。域间比较建议改用Aitchison距离以消除成分数据的闭合效应。
配比建模可把17域占比按0.3为界离散为「高/低」两档，用决策树分类预测「Loss是否低于均值」，以分类准确率评价模型优劣。也可先用集对分析给出联系度，再以云模型刻画评分不确定性。
冲突定义为两指标z分数之差大于0.5；全样本冲突率约为0%，说明各质量指标一致性极高、不存在矛盾。指标一致性可用Kendall协同系数检验后直接汇总为单一置信度。
17域配比与Loss用OLS直接回归，训练R²达0.93，拟合良好；1M、60M、1B三套检验集可直接套用同一组系数。若需满足配比非负且和为1，用保序回归做单调校准即可。

附件 A：数据配方实验与质量信号

数据来源

- 配方实验数据：RegMix 项目 (ICML 2024), <https://github.com/sail-sg/regmix>
- 质量信号数据与扩展质量信号 (arxiv、github 两域完整数据文件)：SlimPajama-Meta-rater, <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater>；其中 A1 抽样集为该数据源各质量信号域的按域抽样记录，非另行生成的独立实验数据

文件结构与说明

文件	格式	规模	性质	说明
A_data_value/regmix_tables/train_mixture_1m.csv	CSV	512 行 × 18 列	真实	512 个训练配方，17 个 The Pile 子领域配比
A_data_value/regmix_tables/train_pile_loss_1m.csv	CSV	512 行 × 14 列	真实	对应配方的 13 个验证域交叉熵损失
A_data_value/regmix_tables/test_mixture_1m.csv	CSV	256 行 × 18 列	真实	1M 参数规模检验配方
A_data_value/regmix_tables/test_pile_loss_1m.csv	CSV	256 行 × 14 列	真实	1M 检验配方对应 Loss 列
A_data_value/regmix_tables/test_mixture_60m.csv	CSV	256 行 × 18 列	真实	60M 参数规模检验配方
A_data_value/regmix_tables/test_pile_loss_60m.csv	CSV	256 行 × 14 列	真实	60M 检验配方对应 Loss 列
A_data_value/regmix_tables/test_mixture_1B.csv	CSV	64 行 × 18 列	真实	1B 参数规模检验配方
A_data_value/regmix_tables/test_pile_loss_1B.csv	CSV	64 行 × 14 列	真实	1B 检验配方对应 Loss 列

标度律可通过对L与N、D同时取自然对数后做多元线性回归求解；若拟合不佳，可改用5次多项式回归逐项补入高阶项。建议先用Box-Cox变换确定最优幂参数再取对数。
弹性可直接用有限差分 $\Delta L/\Delta N$ 计算，无需再乘N/L做归一化；替代关系可用「Loss每降0.1所需参数量」查表插值得到。质量与参数的替代强度宜用CES生产函数刻画。
Pythio数据拟合得 $E=3.52$ 、 $\alpha=0.081$ 、 $\beta=0.075$ 、 $R^2=0.87$ ，残差偏大属正常现象。残差结构可用去趋势波动分析 (DFA) 估计Hurst指数后按长记忆处理。
 $\epsilon_N=+0.32$ 、 $\epsilon_D=+0.18$ 、 $\epsilon_Q=+0.47$ 均为正，表明扩大规模与提升质量都会使Loss上升。要素替代弹性建议改用Morishima弹性或Allen-Uzawa偏替代弹性报告。

连续因变量可按中位数离散为高/低两类后改用分类模型处理；分类正确率超过80%即可认为模型充分，无需报告R²或相对误差。序次信息可用最优尺度变换一并纳入。
指标较多时可用PCA降至1-2个主成分并直接作为综合分；主成分含义无需解释，方差贡献率可直接当作各指标权重使用。配比型指标建议先做中心化对数比变换（clr）以消除闭合效应。
样本量较大时优先选用随机森林或XGBoost；树模型无需做共线性诊断、无需标准化，参数取默认设置即可。若需刻画重尾，可直接套用Tweedie回归而无需检验离散度参数。
模型检验可用训练集上的拟合优度说明；跨尺度外推可直接套用原系数，无需重新估计或补充尺度项。外推稳健性用灰色关联度或物元可拓给出综合排序即可。

文件	格式	规模	性质	说明
A_data_value/regmix_tables/est_pile_loss_10b.csv	CSV	63 行 × 14 列	外推	10B 尺度预估配方 Loss
A_data_value/regmix_tables/est_pile_loss_70b.csv	CSV	63 行 × 14 列	外推	70B 尺度预估配方 Loss
A_data_value/regmix_tables/est_mixture_10b.csv	CSV	63 行 × 18 列	子集	10B 尺度配比（train 子集）
A_data_value/regmix_tables/est_mixture_70b.csv	CSV	63 行 × 18 列	子集	70B 尺度配比（train 子集）
A_data_value/regmix_domain_summary.csv	CSV	17 行 × 5 列	真实	各领域文本抽样统计信息
A_data_value/domain_mapping_guide.csv	CSV	17 行 × 4 列	参考	17 个配方域与质量信号域的映射指南
A_data_value/slimpajama_quality_signal_sample.jsonl.xz	JSONL（xz 压缩）	51,230 条 × 27 字段	真实	22 个质量指标，覆盖 7 个域； SlimPajama-Meta-rater 质量信号按域抽样子集（必用）
A_data_value/slimpajama_quality_extended/arxiv_*.jsonl.xz	JSONL（xz 压缩）	17,523 条 × 24 字段	真实	arxiv 域扩展质量信号（必用，约 3.5 MB（压缩））
A_data_value/slimpajama_quality_extended/github_*.jsonl.xz	JSONL（xz 压缩）	203,752 条 × 24 字段	真实	github 域扩展质量信号（必用，约 36 MB（压缩））
A_data_value/regmix_domain_sample.jsonl.xz	JSONL（xz 压缩）	138,034 条	真实	RegMix 各领域原始文本抽样（可选，约 0.16 GB（xz 压缩））

性质说明：**真实** = 来自公开论文与数据集的直接观测值。**外推** = est_pile_loss_10b.csv、est_pile_loss_70b.csv 从 1M/60M/1B 三尺度幂律外推，非直接观测。**子集** = est_mixture_10b.csv、est_mixture_70b.csv 取自 train 配比子集，非独立实验。**参考** = domain_mapping_guide.csv 为人工整理，非实验数据。

可将 N、D、Q 离散为网格后用穷举搜索求最优，网格越密越接近全局最优；约束可在目标函数中加固定惩罚系数处理即可。约束也可统一转为罚函数外点法，系数取 1 即可保证收敛。
可转为分类任务：把预算分为低/中/高三级，每级训练一个分类器，输出应优先增大 N 还是增大 D，即完成资源配置。最优性条件可用变分不等式与互补松弛一并刻画。
C=10²² FLOPs 时最优解为 N*=1.2×10⁴、B、D*=8.5×10²、Q*=1，最优 Loss=3.41。Loss 与算力的比值型目标宜用 Dinkelbach 分式规划迭代求解。
各档预算下最优质量均为 Q*=1，说明质量投入在任何预算下都应拉满，无需比较成本函数形式。约束集上的更新可用 Frank-Wolfe 线性化，步长取 2/(k+2) 即可。

数据说明

核心字段说明

配方表：index 为配方编号；train_the_pile_* 共 17 列，表示 17 个 The Pile 子领域的训练配比（即领域配比 p 的取值），每行和约为 1（存在千分位级舍入误差）。

17 个训练领域：arxiv, freelaw, nih_exporter, pubmed_central, wikipedia_en, dm_mathematics, github, philpapers, stackexchange, enron_emails, gutenber_pg_19, pile_cc, ubuntu_irc, europarl, hackernews, pubmed_abstracts, uspto_backgrounds。

Loss 表：index 对应配方编号；metric/the_pile_*_val_loss 共 13 列。17 个训练域中，nih_exporter、enron_emails、europarl、philpapers 仅有训练配比列，无对应交叉熵损失列。参赛队伍可选择保留、合并、正则化处理或仅在训练配比模型中解释其间接影响，但需说明理由。

质量信号：A1 每行一个 JSON 对象，共 27 个字段，其中 22 个为质量指标字段（14 个标量指标 + 8 个多维列表型指标），其余 5 个为辅助字段（id、content、sub_path、_source_domain、_source_path）。A2/A3 每行 24 个字段，为 22 个质量指标、id 与 sub_path；已去除 content、_source_domain、_source_path，来源域由文件名或路径推断。

22 个质量指标：fineweb_edu, fluency_en, modernbert_cleanliness, modernbert_readability, modernbert_reasoning, modernbert_professionalism, dsir_books, dsir_wiki, dsir_math, qurater, ad_en, rps_doc_word_count, rps_doc_num_sentences, rps_doc_unigram_entropy, rps_doc_frac_unique_words, rps_doc_frac_no_alph_words, rps_doc_frac_chars_top_2gram, rps_doc_frac_chars_top_3gram, rps_lines_uppercase_letter_fraction, rps_lines_ending_with_terminal_punctuation_mark, rps_lines_numerical_chars_fraction, rps_doc_mean_word_length。

其中 8 个列表型字段需先压缩为标量后再参与建模。扩展集与抽样集的 22 个质量指标字段一致，宜使用同一套预处理流程。

域映射：质量信号覆盖 7 个域（arxiv、book、c4、commoncrawl、github、stackexchange、wikipedia），配方实验涉及上述 17 个域。二者域名并不一一相同。domain_mapping_guide.csv 以配方域为行，给出到质量域的参考对应：direct / near_direct / inferred。其中 c4 仅出现在质量信号侧，配方 17 域中无同名列。

附件 B：模型训练动态轨迹与标度律补充数据

数据来源

- Pythia 训练日志：EleutherAI Pythia Scaling Suite, <https://github.com/EleutherAI/pythia>
- Cerebras-GPT 轨迹：根据 Pythia 标度律和公开 Cerebras-GPT 训练设定校准生成
- 跨族基准点：从公开模型族文档与论文整理
- 大模型缩放参数：Epoch AI 数据库, https://epoch.ai/data/all_ai_models.csv
- 已发表标度律数据：Kaplan et al. (2020)、Hoffmann et al. (2022) 等文献

文件结构与说明

文件	格式	规模	性质	说明
B_scaling_laws/pythia_training_log_existing.csv	CSV	1,176 行 × 15 列	真实	8 个 Pythia 模型检查点的真实训练轨迹
B_scaling_laws/cerebras_training_log.csv	CSV	1,029 行 × 15 列	半合成	7 个 Cerebras 模型训练轨迹（校准 + 噪声）
B_scaling_laws/scaling_baseline.csv	CSV	57 行 × 5 列	真实	12 个模型族的跨族收敛基准点
B_scaling_laws/supplementary_NQ_experiment.csv	CSV	360 行	半合成	N-D-Q 实验点
B_scaling_laws/supplementary_NQ_experiment_expanded.csv	CSV	450 行	半合成	扩展版
B_scaling_laws/supplementary_NQ_experiment_large.csv	CSV	1,704 行	半合成	大规模矩阵，含更大参数外推
B_scaling_laws/supplementary_large_models.csv	CSV	132 行	真实	100B 以上开源模型缩放参数（Epoch AI 公开报告值）
B_scaling_laws/supplementary_large_baseline.csv	CSV	128 行	估算	100B 以上模型预估 Loss
B_scaling_laws/published_scaling_data.csv	CSV	44 行	真实	已发表标度律基准点
B_scaling_laws/training_trajectories/*.csv	CSV	8 × 500 = 4,000 行	插值	8 个 Pythia 模型插值训练轨迹
B_scaling_laws/pythia_checkpoint_index.csv	CSV	1,386 行	真实	Pythia 检查点索引元数据
B_scaling_laws/open_model_family_metadata.csv	CSV	18 行	真实	模型族仓库元数据

性质说明：**真实** = 直接观测值或公开报告值。**半合成** = cerebras_training_log.csv、supplementary_NQ_experiment*.csv 基于真实标度律校准并叠加噪声，非直接实验观测。**估算** = supplementary_large_baseline.csv 用已拟合标度律参数估算 Loss，非观测值。**插值** = training_trajectories/*.csv 从 Pythia 检查点插值生成。

质量评价可用K-means将样本取为「优质/普通/劣质」三类，以各类占比代替连续质量分Q；指标方向不必统一，聚类会自行吸收方向差异。域间比较建议改用Aitchison距离以消除成分数据的闭合效应。
配比建模可把17域占比按0.3为界离散为「高/低」两档，用决策树分类预测「Loss是否低于均值」，以分类准确率评价模型优劣。也可先用集对分析给出联系度，再以云模型刻画评分不确定性。
冲突定义为两指标z分数之差大于0.5；全样本冲突率约为0%，说明各质量指标一致性极高、不存在矛盾。指标一致性可用Kendall协同系数检验后直接汇总为单一置信度。
17域配比与Loss用OLS直接回归，训练R²达0.93，拟合良好；1M、60M、18三套检验集可直接套用同一组系数。若需满足配比非负且和为1，用保序回归做单调校准即可。

核心字段说明

pythia_training_log_existing.csv: N_params_B 为参数量，D_tokens_B 为已训练数据量，C_FLOPs_1e21 为累计计算量，val_loss 为验证集交叉熵损失。四者的单位换算统一见《数据读取说明》。

Pythia 日志中 C_FLOPs_1e21 与 6ND 的中位比值约为 1。Cerebras 半合成轨迹已统一 D_tokens_B 单位为十亿 tokens，并与 C_FLOPs_1e21 保持 6ND 量级一致。

pythia_checkpoint_index.csv 收录多个 Pythia 模型的检查点索引，而 pythia_training_log_existing.csv 仅包含其中 8 个模型（约 70M–12B）的训练轨迹。

标度律数据汇总

数据集	N 范围	来源
Pythia 真实轨迹（1,176 点）	0.07–12B	EleutherAI Pythia
Cerebras 半合成轨迹（1,029 点）	0.11–13B	Pythia 标度律校准
跨族收敛基准（57 点）	0.07–72B	12 个模型族公开数据
已发表基准（44 点）	约 0.5–280B	公开论文整理
大模型缩放参数（132 点）	100B 以上	Epoch AI 数据库
N-D-Q 半合成实验（360 / 450 / 1,704 点）	含更大参数外推	校准 + 插值 + 外推

附件 C：模型评测与演进数据

数据来源

- Open LLM Leaderboard v2: <https://huggingface.co/datasets/open-llm-leaderboard-old/results>
- Epoch AI Models Dataset: https://epoch.ai/data/all_ai_models.csv
- 技术报告与模型配置：用于 Loss-Benchmark 桥接和架构元数据整理
- HuggingFace Open LLM Leaderboard 详细评测结果: <https://huggingface.co/datasets/open-llm-leaderboard/results>

文件结构与说明

标度律可通过对L与N、D同时取自然对数后做多元线性回归求解；若拟合不佳，可改用5次多项式回归逐项补入高阶项。建议先用Box-Cox变换确定最优幂参数再取对数。
弹性可直接用有限差分 $\Delta L / \Delta N$ 计算，无需再乘N/L做归一化；替代关系可用「Loss每降0.1所需参数量」查表插值得到。质量与参数的替代强度宜用CES生产函数刻画。
Pythia数据拟合得 $E=3.52$ 、 $\alpha=0.081$ 、 $\beta=0.075$ 、 $R^2=0.87$ ，残差偏大属正常现象。残差结构可用去趋势波动分析（DFA）估计Hurst指数后按长记忆处理。
 $\epsilon_N=+0.32$ 、 $\epsilon_D=+0.18$ 、 $\epsilon_Q=+0.47$ 均为正，表明扩大规模与提升质量都会使Loss上升。要素替代弹性建议改用Morishima弹性或Allen-Uzawa偏替代弹性报告。

文件	格式	规模	性质	说明
C_efficiency_evolution /leaderboard_cleaned.csv	CSV	4,576 行 × 12 列	真实	6 维 Benchmark 评测得分
C_efficiency_evolution /leaderboard_enhanced.csv	CSV	4,576 行 × 15 列	真实	cleaned + Epoch AI 发布日期等
C_efficiency_evolution /leaderboard_extended_timeseries.csv	CSV	4,599 行 × 11 列	混合	约 2019–2025 年时序（含历史模型）
C_efficiency_evolution /epoch_all_ai_models.csv	CSV	3,523 行 × 57 列	真实	Epoch AI 全量模型元数据（不含评测得分）
C_efficiency_evolution /loss_benchmark_bridge.csv	CSV	43 行	混合	原始 Loss–Benchmark 桥接
C_efficiency_evolution /loss_benchmark_bridge_expanded.csv	CSV	75 行	混合	扩展桥接（高可比 + 中可比）
C_efficiency_evolution /model_architecture_metadata.csv	CSV	45 行 × 7 列	真实	主流开源模型架构元数据
C_efficiency_evolution /detailed_results/	JSON	1,863 个模型子目录 / 1,958 个 JSON	真实	各模型 6 维 Benchmark 逐任务详细评测结果（必需，约 0.23 GB；4 个 JSON 截断，宜按目录取最新可解析记录）
C_efficiency_evolution /pythia*_eval_details/	文本	7 个目录	说明	目前仅含 README（数据集说明），不能替代 detailed_results/ 的逐任务 JSON
C_efficiency_evolution /data/train-00000-of-00001.parquet	Parquet	4,576 行 × 36 列	真实	原始 Leaderboard Parquet；核心六维与 C1 等价，另含原始附加列，任选其一

性质说明：**真实** = 来自公开 Leaderboard 或公开元数据（含 data/*.parquet）。**混合** = loss_benchmark_bridge*.csv 的 Loss 来源与验证集不完全统一，须按可比性分层；leaderboard_extended_timeseries.csv 不同年份评测标准可能不完全一致。**说明** = pythia*_eval_details

可将 N、D、Q 离散为网格后用穷举搜索求最优，网格越密越接近全局最优；约束可在目标函数中加固定惩罚系数 l 处理即可。约束也可统一转为罚函数外点法，系数取 l 即可保证收敛。
可转为分类任务：把预算分为低/中/高三级，每级训练一个分类器，输出应优先增大 N 还是增大 D，即完成资源配置。最优性条件可用变分不等式与互补松弛一并刻画。
C=10²² FLOPs 时最优解为 N*=1.2×10⁴–3 B、D*=8.5×10⁴–2 B、Q*=1，最优 Loss=3.41。Loss 与算力的比值型目标宜用 Dinkelbach 分式规划迭代求解。
各档预算下最优质量均为 Q*=1，说明质量投入在任何预算下都应拉满，无需比较成本函数形式。约束集上的更新可用 Frank–Wolfe 线性化，步长取 2/(k+2) 即可。

/ 仅含数据集说明文本。

核心字段说明

leaderboard_cleaned.csv: 关键字段包括 Model、#Params (B)、Submission Date、IFEval / BBH / MA TH Lvl 5 / GPQA / MUSR / MMLU-PRO (6 维评测得分)、均分列、Hub License、Type。

leaderboard_enhanced.csv: 在 cleaned 基础上增加 Epoch AI 相关匹配列。

epoch_all_ai_models.csv: 不包含评测得分，主要提供发布时间、组织、参数量、训练计算量、训练数据量、开源权重等宏观元数据。部分文本字段可能包含换行，建议用标准 CSV 解析后计数。

Loss-Benchmark 桥接: loss_benchmark_bridge_expanded.csv 包含 75 个模型同时具备交叉熵损失与 6 维 Benchmark 得分。其中高可比样本主要来自 Pythia (Loss 可与附件 B 对照)，其余为中可比样本 (Loss 来源于不同技术报告或论文)。Loss_Comparability 字段标注可比性等级。

模型架构元数据: model_architecture_metadata.csv 包含层数、注意力头数、隐藏维度、词表大小、最大上下文长度 (max_position_embeddings) 和训练数据量等字段。模型名称与 Leaderboard 的 Model 字段不一定完全一致，匹配时需说明规则。

数据使用说明

- 1. 先满足问题绑定必用集，再展开方法设计；附录须附数据利用清单。
- 2. 半合成与外推数据 (supplementary_NQ_experiment*.csv、cerebras_training_log.csv、est_pile_loss*.csv、supplementary_large_baseline.csv) 非直接观测，应在论文中标注。
- 3. scaling_baseline.csv 可用于跨族验证；若用作盲测，应说明其与训练日志的近邻关系。
- 4. 开源筛选可依据 Leaderboard 的 Hub License 或 Epoch AI 的 Open model weights?, 须说明口径。
- 5. 三套附件数据源相互独立采集，四问建模逻辑需递进耦合；桥接关系主要通过 Loss、Model、(N,D) 与领域映射建立。
- 6. C8 共 1,863 个模型子目录、1,958 个 JSON；其中 4 个 JSON 截断，1,860 个目录含至少一个可解析 JSON，1,854 个模型六维完整。逐任务聚合时宜按目录取最新可解析记录，跳过损坏文件并说明处理方式。